

聚合平台

平台	免费性质	免费模型	链接
火山引擎 (Ark)	每模型 50 万 Token 免费额度（长期）	DeepSeek-V4, Kimi-K2.6, GLM-5.2, Doubao-Seed-2.0-Pro 等 12+ 款	volcengine.com
硅基流动 (SiliconFlow)	9B 以下模型永久免费；新用户送 16 元额度	Qwen2.5-7B, GLM-4-9B, DeepSeek-R1-Distill, InternLM2.5-7B	siliconflow.cn
OpenRouter	提供 20+ 款完全免费模型（有速率限制）	Gemini 2.0 Flash, Llama 3.3 70B, DeepSeek-R1, Qwen3 Coder 480B	openrouter.ai
NVIDIA NIM	免费原型开发（需加入开发者计划）	DeepSeek V3.2, Llama 4, Qwen 3.5, Kimi K2, GLM-5.2 等 31+ 款	build.nvidia.com
Groq	免费层级：每日 14,400 次请求（极速推理）	Llama 3.3 70B, Gemma 2 9B, Mixtral 8x7B, GPT-OSS 120B	console.groq.com
Cerebras	每日 100 万 Token 免费；每日 14,400 次请求	Llama 3.3 70B, Llama 4 Scout, Qwen3 32B, GPT-OSS-120B	cloud.cerebras.ai
Together AI	注册送 \$5 额度；部分模型免费	Llama 3.3 70B, Qwen 2.5, DeepSeek R1, Gemma, Mistral Nemo	together.ai
FreeLLMAPI	整合多家免费额度（开源网关）	聚合 Google Gemini、Groq、Mistral、OpenRouter、智谱、Kimi 等	github.com/MrFadiAi/free-llm-gateway
GitHub Models	免费试用（需 GitHub 账号）	GPT-4o, DeepSeek-R1, Llama 3.3, Mistral, Grok 3	github.com
Cloudflare Workers AI	每日 10,000 Neurons 免费额度	平台内所有 Workers AI 模型	developers.cloudflare.com/workers-ai

国外模型

平台	免费性质	模型名称	模型网址
OpenRouter	免费路由器；自动选择可用免费模型	openrouter/free	openrouter.ai/openrouter/free
OpenRouter	免费模型；rate limited	nvidia/nemotron-3-ultra-550b-a55b:free	openrouter.ai/nvidia/nemotron-3-ultra-550b-a55b%3Afree
OpenRouter	免费模型；长上文、多模态	minimax/minimax-m3:free	openrouter.ai/minimax/minimax-m3%3Afree
OpenRouter	免费模型；偏 coding agent	poolside/laguna-s-2.1:free	openrouter.ai/poolside/laguna-s-2.1%3Afree
OpenRouter	免费模型；偏 coding agent 小版本	poolside/laguna-xs-2.1:free	openrouter.ai/poolside/laguna-xs-2.1%3Afree
OpenRouter	免费模型；rate limited	nvidia/nemotron-3-super-120b-a12b:free	openrouter.ai/nvidia/nemotron-3-super-120b-a12b%3Afree
OpenRouter	免费模型；适合 agentic harness	thinkingmachines/inkling:free	openrouter.ai/thinkingmachines/inkling%3Afree
OpenRouter	免费模型；较小版本	thinkingmachines/inkling-small:free	openrouter.ai/thinkingmachines/inkling-small%3Afree
OpenRouter	免费 embedding；适合 RAG / 检索 agent	nvidia/nemotron-3-embed-1b:free	openrouter.ai/nvidia/nemotron-3-embed-1b%3Afree
Google Gemini API	Free Tier；部分模型输入/输出免费	gemini-3.5-flash-lite	ai.google.dev/gemini-api/docs/models
Google Gemini API	Free Tier；适合轻量 agent	gemini-3.5-flash	ai.google.dev/gemini-api/docs/pricing
Google Gemini API	Free Tier；Flash 系列	gemini-3.7-flash / gemini-3.6-flash	ai.google.dev/gemini-api/docs/models
Mistral La Plateforme	Free mode；有 included monthly usage	Mistral API models / Codestral 等	docs.mistral.ai/admin/billing-usage/usage-limits
Groq	开发者低额度/限额使用；OpenAI-compatible	openai/gpt-oss-120b	console.groq.com/docs/models
Groq	开发者低额度/限额使用	openai/gpt-oss-20b	console.groq.com/docs/models

Groq	Agentic system; 内置工具能力	groq/compound	console.groq.com/docs/models
Groq	Agentic system; 轻量版	groq/compound-mini	console.groq.com/docs/models
Cloudflare Workers AI	每天 10,000 Neurons 免费额度	Workers AI 模型目录内模型	developers.cloudflare.com/workers-ai/models/
Hugging Face	免费用户每月少量 credits	Inference Providers 可用模型	huggingface.co/docs/inference-providers/en/pricing
Cerebras	\$5 / 30 天试用额度; 非长期免费	gpt-oss-120b / gemma-4-31b	inference-docs.cerebras.ai/models/overview

国内模型

模型名称（所属平台）	免费额度 & 备注	链接
智谱 GLM-4.7-Flash	✅ 完全免费（200K 上下文）；新用户另赠 2000 万 Token	open.bigmodel.cn
智谱 CogView-3-Flash	✅ 完全免费（图像生成）	open.bigmodel.cn
智谱 CogVideoX-Flash	✅ 完全免费（视频生成）	open.bigmodel.cn
阿里云 Qwen-Max / Plus / Flash	新用户每模型 100 万 Token（有效期 90 天）	bailian.aliyun.com
腾讯混元 Hunyuan-lite	✅ 永久免费（并发 5 路）	cloud.tencent.com/product/hunyuan
腾讯混元（其他模型）	首次开通赠 100 万 Token	cloud.tencent.com/product/hunyuan
商汤 SenseNova	公测期间每 5 小时 1500 次免费请求	platform.sensenova.cn
深度求索 DeepSeek	新用户注册送 500 万 Token（30 天有效）	platform.deepseek.com
讯飞星火 Spark-Lite	✅ 永久免费，总量无限（QPS=2）	xinghuo.xfyun.cn
讯飞星火 Spark-Max	可免费领取 1 亿 Tokens	xinghuo.xfyun.cn
百度文心 ERNIE-Speed / Lite	✅ 永久免费不限量	qianfan.baidubce.com
百度文心（其他模型）	新用户每模型 100 万 Token / 3 个月	qianfan.baidubce.com
月之暗面 Kimi	免费版每 30 天 \$5 额度（或每日 100 万 Token）	platform.moonshot.cn
MiniMax	新用户免费试用额度（RPM=20）	platform.minimaxi.com