

爬虫

https://github.com/shortyZhou/CaseB_Crawler

前言

对于爬虫来说，除了技术手段，合规性也很重要（如果谁因为非法爬取数据进去了，不要说是看这个pdf学的）

该案例研究了网页公开信息爬取、微信公众号公开文章爬取的3种方式，大家请按自身需求学习和实践本案例，支持多多加入自己的设计

如果希望爬取的数据导入Excel / Word并做分析的，记得安装Excel / Word相关的skills

该案例仅用于个人研究，不可公开分享或用作商业用途。感谢所有案例中涉及的网址，如有侵权请联系我，我立刻删除

环境配置

在Hermes中创建全新的profile，导入合适的SOUL

在本地创建一个新文件夹作为project的路径

我现在希望这个project的路径都用C:\Users\24779\Desktop\AI related\CaseB_Crawler，像在VSCode里打开环境文件夹那样，生成的code、文件都放在这个路径下

SOUL设计要点：

- 提示高风险或违法爬虫行为，不强制破解访问控制
- 不捏造数据和来源，标注不确定性
- 可适应或绕过反爬机制，选择最轻量有效方法

我设计的SOUL放在prompts/SOUL.md，仅供参考

A. 直接爬取网站/网页内容

适用于指定一个网站/网页爬取信息，例如某公司官网、某微信公众号的某篇文章（网页版）


工具安装

根据需求查找需要的工具，发现Hermes自带网页搜索web_search和内容提取web_extract工具

另可安装以下skill/MCP/到project（在安装任何工具时都要注意它是否适配Hermes）：

- Scrapling CLI & Scrapling skill
- mcp-webscraper: <https://www.npmjs.com/package/mcp-webscraper>

如果控制在project安装和启动，agent会在project地址生成一个新的入口，双击这个入口打开的Hermes才会启用mcp-webscraper



Workflow设计

根据需求设计workflow，可借助deepseek/chatgpt生成workflow的prompt

我设计的prompt放在prompts/ A_prompt.md，仅供参考

【任务】

用户指定要爬取的网站/网页，使用 Hermes 的网页抓取能力配合 Scrapling CLI、Scrapling skill 和 mcp-webscraper，检索并提取指定内容。

【执行步骤】

1. 使用 ``web_extract`` 工具尝试抓取指定的网站/网页信息，输出为 Markdown 格式。
2. 分析抓取结果。
3. 如果 ``web_extract`` 返回的内容不完整或缺失信息，使用 ``browser_navigate`` 和 ``browser_snapshot`` 工具查看页面结构，定位相关内容的 CSS 选择器。
4. 如果页面是 JavaScript 动态渲染的，使用 Scrapling 的 ``dynamic`` 或 ``stealth`` 模式重新抓取。
5. 将提取到的信息整理为结构化的 Markdown 格式输出。
6. 把 Markdown 格式的输出打印到当前会话框。

【重要提醒】

- 请求间隔建议保持 3-5 秒，避免对目标网站造成负担。
- 仅用于个人研究，不要公开分享或用于商业用途。
- 如果遇到反爬机制，优先尝试 Scrapling skill 的 stealth 模式。

测试用例1： 公司网站

<https://www.fuwuzaixian.cn/>

根据C:\Users\24779\Desktop\AI related\CaseB_Crawler\A_prompt.md这个 workflows，帮我查找在 [fuwuzaixian.cn](https://www.fuwuzaixian.cn/) 网站中，关于萤石或氢氟酸的价格、产量、消费、进出口量的数据，打印在当前对话框

有些数据涉及会员登录、验证码验证，可能掺杂部分手动授权的操作，跟随agent的指示做

我把抓取到的结果整理成表格放入excel了，在results/A_result.xlsx，仅供参考

整理以上结果到excel（如果内容涉及表格请整理成表格形式）并放在C:\Users\24779\Desktop\AI related\CaseB_Crawler\results地址下，命名excel为A_result_1

也可以在设计workflow的时候直接要求把爬取结果以什么格式输出放到什么位置

包括要爬取数据的时间频次、表格格式，都可以自己设计

测试用例2：微信公众号文章（网页版）

https://mp.weixin.qq.com/s/c2l_RYmeYVaDeR4gO9HU6Q

根据C:\Users\24779\Desktop\AI related\CaseB_Crawler\A_prompt.md这个工作流，帮我在微信公众号文章 mp.weixin.qq.com/s/c2l_RYmeYVaDeR4gO9HU6Q 中，查找关于萤石或氢氟酸的价格、产量、消费、进出口量的数据，默认使用谷歌浏览器打开网址，把结果打印在当前对话框

我把抓取到的结果整理成表格放入excel了，在results/A_result.xlsx，仅供参考

可以在设计workflow的时候要求爬取结果以什么格式输出、放到什么位置
包括要爬取数据的时间频次、表格格式，都可以自己设计

B. 基于搜狗微信搜索

<https://weixin.sogou.com/>

在搜狗微信，按关键词跨公众号检索文章，无需登录账号


工具安装

根据需求查找需要的工具，注意在安装任何工具时都要注意它是否适配Hermes

安装以下MCP到project:

dsh-wechat-mp-search: <https://www.npmjs.com/package/dsh-wechat-mp-search>

同样的，dsh-wechat-mp-search也需要通过新入口打开Hermes才会启用，记得安装完MCP要测试其能否使用



Workflow设计

根据需求设计workflow，可借助deepseek/chatgpt生成workflow的prompt

我设计的prompt放在prompts/ B_prompt.md，仅供参考

这个prompt设计得更为具体和有任务指向性，大家一定要根据自己的需求来设计、测试、debug和完善

【任务】

使用 `dsh-wechat-mp-search` MCP 工具，通过搜狗微信搜索，按用户要求检索相关的微信公众号文章。检索自动翻 3 页即可。对检符合要求的文章，获取标题和正文中用户想要的内容。如果没有符合要求的文章，也要如实反馈给用户。

【可用工具】

- MCP 工具（Hermes 中已配置 `dsh-wechat-mp-search`）：
 - `weixin_search_all`: 自动翻页搜索
 - `get_weixin_article_content`: 获取文章正文

【执行步骤】

1. 确认 MCP 连接正常：
在 Hermes 中运行 `/reload-mcp`，确认工具列表中有 `mcp__dsh-wechat-mp-search__weixin_search_all` 和 `mcp__dsh-wechat-mp-search__get_weixin_article_content`。
2. 执行搜索（自动翻 3 页）：
调用 `weixin_search_all`，参数：
 - `max_pages = 3`
每个查询都设置 `max_pages = 3`，但总共不要超过 6 页请求。
3. 对搜索结果中的每篇文章，调用 `get_weixin_article_content` 获取正文：
 - 参数 `real_url` = 搜索结果中的 `real_url`
 - `referer` = 搜索结果中的 `link`（可选，建议带上）

测试用例： 搜狗微信搜索公众号文章

<https://weixin.sogou.com/>

根据C:\Users\24779\Desktop\AI related\CaseB_Crawler\prompts\B_prompt.md这个工作流，帮我按照格式“【氟化工】9月X日市场行情简报”（X为具体数字），查找9月9日到9月11日每天的市场行情简报文章（提供文章的公众号指定为“氟务在线”）。并提取关于萤石或氢氟酸的价格、产量、消费、进出口量的数据，打印在当前对话框

大家注意要在合规性与对抗反爬机制之间，做好平衡与取舍，灵活调整SOUL的道德水平
灵活配置版的SOUL放在prompts/SOUL2.md，仅供参考

我把抓取到的结果整理成表格放入excel了，在results/B_result.xlsx，仅供参考

C. 基于微信公众平台官方 API

需要登录自己的微信公众号后台以获取合法凭证，再调用平台内部接口来抓取数据，过于高频的调用会触发访问限制

工具安装

根据需求查找需要的工具，注意在安装任何工具时都要注意它是否适配Hermes

安装以下工具：

wechat-search CLI

weixin-public-account-skill: <https://github.com/qbul1/weixin-public-account-skill>

并要求agent做Hermes适配调整

Workflow设计

wechat-search工具是有自己的使用工作流的：

步骤 1：登录获取凭证 **wechat-search login**

按照agent提示扫码登录自己的微信公众号后台（最好用小号）

注意！登录凭证大约 4 天后过期，需要重新扫码登录

步骤 2：检查登录状态 **wechat-search status**

登陆后agent会自动检查

步骤 3：搜索目标公众号 **wechat-search search “公众号名称” → 获取fakeid**

Workflow设计

之后才能根据设计的prompt去实操，同样的，根据需求设计workflow，可借助deepseek/chatgpt生成workflow的prompt

我设计的prompt放在prompts/ C_prompt.md，仅供参考

注意！要设置访问间隔时间尽量长一些，微信公众平台需要实名认证过，不然很容易触发访问限制

机制升级

在我调研爬虫工具的时候，发现这个方法还有一个升级版：

安装wechat-article-spider: <https://github.com/qbul1/wechat-article-spider>

或者wechat-download-api: <https://github.com/tmwgsicp/wechat-download-api>

前3个步骤和之前的workflow一模一样，不同指出在于之后要使用RSS订阅（有些公众号没有官方公开的RSS方案，用第三方的方案会存在风险，自己配置会很麻烦），优点是被反爬的风险小、速度快。

感兴趣的可以自行了解并按照agent的指引安装、调试、测试。